Problemas inversos con objetivos mixtos y restricciones de igualdad sobre redes neuronales sustitutas

S. Scala[a], R. Lopez[a]

[a] *Artelnics, Salamanca, Espana*

Abstract

El diseno industrial optimo suele plantearse como la busqueda de un unico punto optimo sobre un modelo sustituto entrenado con datos. Muchos problemas de ingenieria, sin embargo, no piden un optimo sino *una especificacion*: un valor objetivo que debe alcanzarse exactamente (un acabado, una dureza, una carga). En este trabajo tratamos el diseno inverso como la recuperacion del *conjunto factible completo* (la variedad de soluciones) que satisface una especificacion impuesta como restriccion de igualdad sobre la salida de una red neuronal sustituta. Sobre ese planteamiento construimos un esquema de optimizacion de respuesta de *sentido mixto*, en el que distintas salidas del mismo problema pueden minimizarse, maximizarse o fijarse simultaneamente, y un criterio de seleccion que ordena las soluciones de la variedad por su *robustez*, calculada con el Jacobiano analitico de la red, equilibrada con su centralidad en el dominio. El metodo maneja de forma nativa restricciones de caja, afines (incluido el simplex composicional) y no lineales. Lo validamos en dos casos con datos reales y solo variables numericas: el torneado CNC de acero inoxidable AISI 304 (fijar la rugosidad, minimizar la fuerza de corte y maximizar la tasa de arranque de material) y la dureza de aleaciones de alta entropia sobre el simplex de composicion (fijar la dureza y recuperar la variedad de aleaciones factibles). En ambos casos se recupera una variedad rica y diversa de disenos que cumplen la especificacion, con satisfaccion exacta de las restricciones afines, y se selecciona de ella el diseno mas robusto. Una comparacion honesta, en la que damos la misma reparacion a las lineas base, muestra que la reparacion es el factor decisivo de factibilidad (sin ella la restriccion de simplex es inviable por muestreo) y que la aportacion propia del metodo son los objetivos de sentido mixto y la seleccion por robustez; con el mismo presupuesto de evaluaciones, nuestro metodo iguala a los mejores optimizadores de proposito general en el objetivo escalar y ademas devuelve,

en la misma pasada, la variedad completa y su ordenacion por robustez. La variedad que recupera es, ademas, la que menos extrapola el sustituto: se mantiene mas cerca de los datos de entrenamiento que las de las lineas base.

Keywords: diseno inverso, optimizacion de respuesta, redes neuronales sustitutas, restricciones de igualdad, robustez, objetivos mixtos

---

1. Introduccion

La cadena habitual del diseno industrial guiado por datos entrena un modelo sustituto $f : \mathbb{R}^p \to \mathbb{R}^q$ (a menudo una red neuronal) sobre medidas experimentales o de simulacion, y despues busca condiciones de operacion que optimicen una o varias salidas. En un trabajo companion abordamos esta busqueda como *optimizacion de respuesta*, con estrategias sin derivadas que explotan el bajo coste de evaluar la red y proyectan (reparan) las muestras sobre las restricciones antes de evaluarlas, garantizando la factibilidad por construccion (Scala y Lopez, 2026). El operador de reparacion de restricciones es maquinaria comun de esa linea; en este trabajo lo reutilizamos y no lo reclamamos como aportacion.

Aquel planteamiento devuelve un unico optimo factible (o un frente de Pareto). Aqui adoptamos una perspectiva distinta, la del *problema inverso*. Ademas, una parte importante de los problemas de ingenieria no se formula como "optimizar", sino como "alcanzar una especificacion": fabricar una pieza con un acabado superficial dado, una aleacion con una dureza dada, un proceso que opere a una carga dada. En estos casos el objetivo natural es una *restriccion de igualdad* sobre la salida, $f_k(\mathbf{x}) = c$, y su solucion no es un punto sino una *variedad*: el conjunto de todas las recetas que cumplen la especificacion. Recuperar esa variedad, en lugar de un solo representante, tiene valor practico directo: permite elegir despues, entre todas las soluciones equivalentes en la especificacion, la que mejor satisface criterios secundarios (coste, productividad) o la mas robusta frente a errores de fabricacion.

Este articulo desarrolla esa idea con tres contribuciones. Primera, planteamos el diseno inverso como la recuperacion de la variedad factible definida por una o varias restricciones de igualdad sobre la red sustituta (Seccion 2). Segunda, generalizamos la formulacion a *objetivos de sentido mixto*, en los que sobre un mismo problema conviven salidas a minimizar, a maximizar y a fijar. Tercera, introducimos un criterio de seleccion que ordena las soluciones de la variedad por robustez, medida con el Jacobiano analitico de la red y

ponderada por el dominio, y la equilibra con la centralidad del punto en la caja de diseno. El metodo se valida en dos casos con datos reales y variables numericas (Secciones 3 y 4).

2. Optimizacion de respuesta de sentido mixto

2.1. Planteamiento

Sea $f : \mathcal{X} \subseteq \mathbb{R}^p \to \mathbb{R}^q$ una red neuronal entrenada, con entradas $\mathbf{x}$ acotadas a una caja $\mathcal{X} = \prod_i [l_i, u_i]$. A cada salida j se le asigna un *sentido* $s_j \in \{\min, \max, \text{fijo}\}$. Las salidas "fijo" llevan un valor objetivo c_j; las salidas "min"/"max" definen los objetivos de optimizacion. Ademas se admiten restricciones sobre entradas y salidas: de caja, afines $\mathbf{a}^\top \mathbf{x} \bowtie \beta$ (incluido el simplex $\sum_i x_i = 1$) y no lineales $g(\mathbf{x}) \bowtie \beta$.

2.2. Objetivo fijo y variedad factible

Un objetivo de igualdad $f_k(\mathbf{x}) = c_k$ se impone como una banda estrecha $|f_k(\mathbf{x}) - c_k| \leq \varepsilon$ alrededor del valor objetivo. El optimizador muestrea el dominio, repara las muestras sobre las restricciones afines, evalua la red y retiene las que caen en la banda, contrayendo iterativamente el dominio alrededor de la region factible. El resultado no es un punto sino un conjunto de soluciones $\{\mathbf{x}^{(r)}\}$ que aproxima la variedad $\mathcal{M}_c = \{\mathbf{x} \in \mathcal{X} : f_k(\mathbf{x}) = c_k\}$.

2.3. Sentidos mixtos

Cuando junto a una salida fija coexisten salidas a minimizar o maximizar, la igualdad se mantiene como banda y los sentidos min/max se optimizan sobre ella, devolviendo el frente de compromiso restringido a la variedad. Asi, un mismo problema puede, por ejemplo, *fijar* una salida, *minimizar* otra y *maximizar* una tercera, que es exactamente la situacion del caso 3. Fijar simultaneamente dos salidas ($f_{k_1} = c_1$ y $f_{k_2} = c_2$) recupera la interseccion de dos variedades.

2.4. Robustez y seleccion

Todas las soluciones de $\mathcal{M}_c$ cumplen la especificacion por igual; se distinguen por su sensibilidad a errores en las entradas. Definimos la robustez de una solucion mediante el Jacobiano analitico de la red, ponderado por el tamano del dominio de cada entrada,

$$S(\mathbf{x}) \;=\; \sqrt{\sum_{i=1}^{p} \Big(\frac{\partial f_k}{\partial x_i}(\mathbf{x}) \, (u_i - l_i) \Big)^2}, \tag{1}$$

de modo que S estima la deriva de la salida si cada entrada se desviara en una fraccion de su rango. Un valor menor indica un diseno mas manufacturable. El Jacobiano se obtiene con el mismo motor de diferenciacion que emplea el optimizador (validado frente a diferencias finitas). La seleccion final combina robustez y *centralidad* $C(\mathbf{x})$, definida como el menor margen normalizado de la solucion a las paredes de la caja de diseno (1 en el centro, 0 sobre una pared), con un unico parametro $\alpha \in [0, 1]$ mediante la media geometrica $C^{1-\alpha} R^{\alpha}$, de forma que $\alpha = 0$ elige el diseno mas central y $\alpha = 1$ el mas robusto.

La centralidad no es un mero desempate: es una salvaguarda frente al propio modelo. La robustez S se estima con el Jacobiano del *sustituto*, y ese sustituto solo es fiable dentro del soporte de los datos de entrenamiento. Una solucion con margen pequeno se situa en el borde de la caja, justo donde la red extrapola y sus unidades se saturan; alli su Jacobiano, y por tanto la robustez que le atribuimos, es menos digno de confianza. Por eso, ante el riesgo de extrapolacion, conviene preferir un punto mas central (un α moderado, en torno a 0,5) que sacrifica algo de robustez nominal a cambio de una prediccion en la que podemos confiar. La seleccion se resuelve sobre cada variedad por separado, de modo que el punto equilibrado depende de la geometria concreta de $\mathcal{M}_c$.

3. Caso A: torneado CNC de AISI 304

Datos y sustituto. Partimos de una campana factorial replicada de torneado de acero inoxidable austenitico AISI 304 (Canal y Borille, 2022). Las variables de decision (numericas) son la velocidad de corte v_c, el avance f y la profundidad de pasada a_p, junto con el estado de desgaste de la herramienta VB tratado como variable numerica. Las respuestas son la rugosidad media R_a y la fuerza de corte resultante F; la tasa de arranque de material $\mathrm{MRR} = v_c\, f\, a_p$ es analitica. Entrenamos una red sustituta multisalida $(v_c, f, a_p, VB) \to (R_a, F)$ con seleccion de arquitectura de neuronas. La fuerza se predice con precision ($R^2 \approx 0{,}99$); la rugosidad, dominada por el avance pero con dispersion de replicas, alcanza $R^2 \approx 0{,}7$ y su dispersion define la tolerancia natural de la banda de igualdad.

Diseno de sentido mixto. Planteamos el problema mixto: *fijar* R_a en una especificacion de acabado, *minimizar* la fuerza F y *maximizar* la productividad MRR. Fijado el objetivo de rugosidad en un valor alcanzable del rango

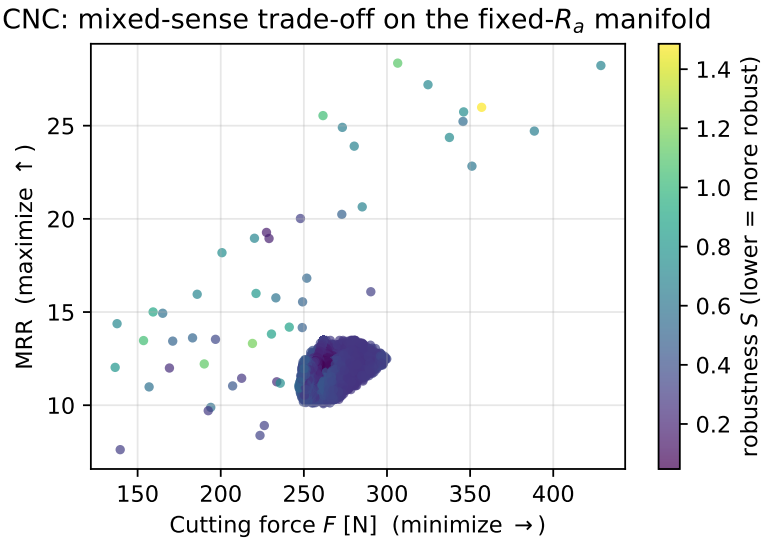


Figura 1: Caso A. Compromiso de sentido mixto sobre la variedad de R_a fijo: cada punto es una receta con la rugosidad en la especificacion; el eje horizontal es la fuerza a minimizar y el vertical la MRR a maximizar, coloreados por la robustez S de la ecuacion (1).

del sustituto (aqui $R_a \approx 0{,}62$ μm), el optimizador recupera una variedad de **3400 recetas** que mantienen R_a dentro de la banda $[0{,}605, 0{,}638]$ μm. Sobre esa variedad, la fuerza recorre $[136, 429]$ N y la MRR $[7{,}6, 28{,}4]$, de modo que la minimizacion de F y la maximizacion de la MRR compiten a lo largo del conjunto factible (Figura 1). Como el problema solo tiene tres palancas continuas, la variedad de R_a constante es una superficie bidimensional directamente visualizable en el espacio de decision (Figura 2).

Seleccion y multiobjetivo de igualdad. El criterio de la Seccion 2.4 devuelve recetas distintas segun α (mas central frente a mas robusta), que difieren claramente en fuerza y productividad sobre la misma especificacion de rugosidad. La diferencia no es solo de valor: sobre esta variedad de 3400 recetas, la receta de robustez pura ($\alpha = 1$) tiene un margen a las paredes de apenas 0,07, es decir, se apoya casi sobre el borde de la caja de entrenamiento, donde el sustituto extrapola; al bajar a $\alpha = 0{,}5$ y $\alpha = 0$ el margen sube a 0,39 y 0,69, devolviendo recetas en el interior bien muestreado del dominio. En la practica preferimos ese punto mas central como cobertura frente al riesgo de extrapolacion del modelo (Seccion 2.4). Al anadir la minimizacion explicita

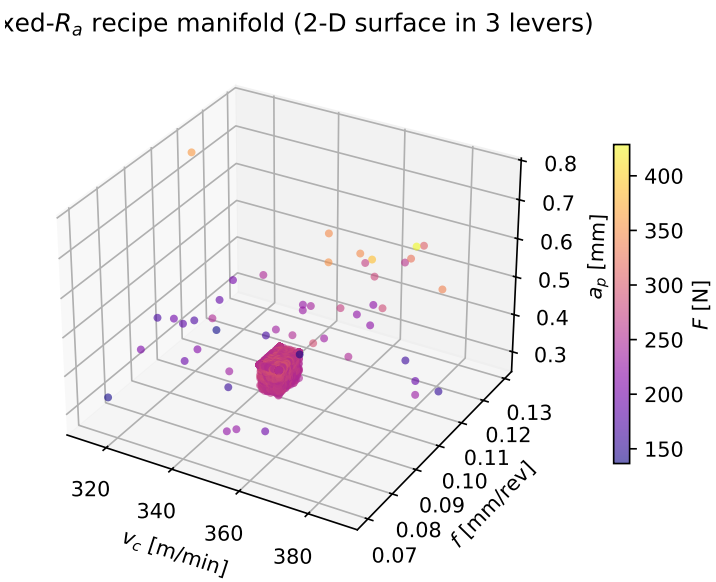


Figura 2: Caso A. La variedad de recetas con R_a fijo es una superficie bidimensional en las tres palancas continuas (v_c, f, a_p), coloreada por la fuerza de corte F.

de F bajo la rugosidad fija, el solver alcanza una receta de fuerza minima ($F \approx 78$ N). Finalmente, fijando simultaneamente R_a y F se recupera la interseccion de ambas variedades (5100 soluciones), que ilustra la capacidad multiobjetivo de igualdad.

4. Caso B: dureza de aleaciones de alta entropia sobre el simplex

Datos y sustituto. El segundo caso usa una tabla publica de dureza Vickers de aleaciones de alta entropia (Wen et al., 2019). Las entradas son las diez fracciones atomicas (Al, Co, Cr, Cu, Fe, Mn, Mo, Ni, Ti, V), que suman uno, y la salida es la dureza HV. El sustituto alcanza $R^2 \approx 0{,}87$ sobre 370 aleaciones. La composicion impone la restriccion afin de *simplex* $\sum_i x_i = 1$, la prueba canonica del operador de reparacion afin.

Recuperacion de la variedad de aleaciones. Fijamos la dureza en un valor alcanzable ($HV \approx 546$) y recuperamos la variedad de composiciones que la producen. El optimizador devuelve **170 aleaciones** distintas, todas sobre el simplex con error maximo $|\sum_i x_i - 1| = 0$ (satisfaccion exacta de la restriccion afin). La variedad es diversa: cada fraccion recorre entre el 44 % y

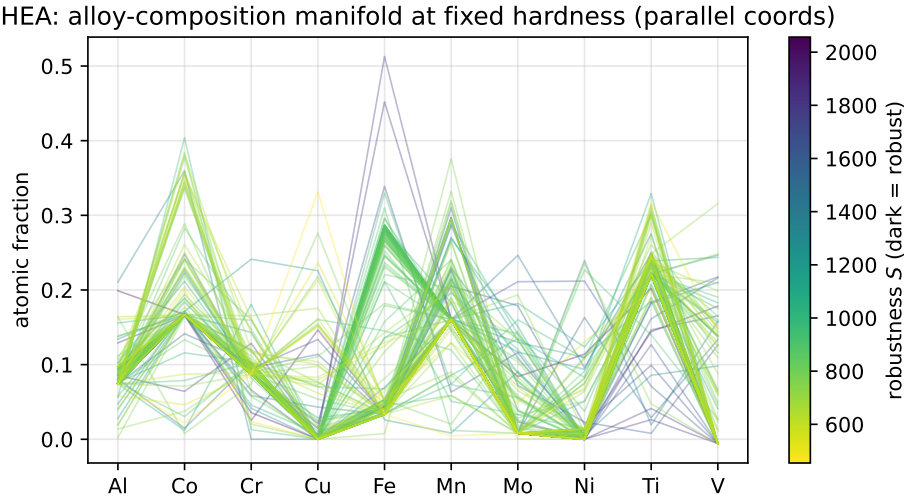


Figura 3: Caso B. Variedad de composiciones con dureza fija, en coordenadas paralelas sobre las diez fracciones atomicas (suma uno). El color codifica la robustez S; las trayectorias oscuras son las aleaciones mas robustas.

el 99 % de su rango admisible (Figura 3), lo que muestra que existen familias de aleaciones muy distintas con la misma dureza. Sobre ese conjunto, la robustez de la ecuacion (1) separa las composiciones poco sensibles a la variacion de composicion de las muy sensibles, y la seleccion centralidad–robustez recomienda la aleacion mas manufacturable.

5. Comparacion honesta con lineas base

Para separar la aportacion real del metodo de la de la reparacion, damos a las lineas base *el mismo operador de reparacion* que usa nuestro metodo. Sobre un presupuesto comparable de evaluaciones y con un criterio de factibilidad identico (banda de igualdad en la salida mas la restriccion de simplex en las entradas), comparamos: muestreo por rechazo *sin* reparacion; muestreo por rechazo *con* reparacion (una ronda de muestreo, reparacion afin de entradas, reparacion de la salida y filtrado, exactamente los mismos operadores); nuestro metodo iterativo con contraccion del dominio; y un algoritmo evolutivo (NSGA-II, con codificacion real, cruce SBX y mutacion polinomica) que optimiza los objetivos *reales* del problema y recibe el *mismo* operador de reparacion en cada generacion. Todas las lineas base reciben el

Cuadro 1: Comparacion con la misma reparacion, mismo presupuesto de evaluaciones ($1{,}2 \times 10^4$ para todos los metodos) y criterio de factibilidad identico (banda de igualdad y simplex). Cobertura = relleno medio del dominio por las soluciones factibles; robustez = menor S disponible en el conjunto devuelto (seleccion posterior, menor es mejor; ningun metodo optimiza S). Caso CNC; la HEA se comenta en el texto.

Metodo	Reparacion	Factib.	Cobertura	Robustez min S
Rechazo	no	7.6 %	99.8 %	**0.055**
Rechazo	si	**23.1 %**	**99.96 %**	0.094
Nuestro (iterativo)	si	4.2 %	78.6 %	0.278
NSGA-II	si	0.8 %	45.2 %	0.853

mismo sustituto congelado, las mismas restricciones y el mismo presupuesto de evaluaciones. La Tabla 1 resume los resultados y la Figura 4 ilustra el analisis de extrapolacion que los distingue.

Protocolo. El presupuesto es de $1{,}2 \times 10^4$ evaluaciones del sustituto para todos los metodos, contado con el numero real de propagaciones directas (incluidas las de la reparacion). Para que la comparacion sea estrictamente equitativa, ajustamos nuestro metodo a 6 iteraciones de 2×10^3 muestras: con esta configuracion la contraccion no puede detenerse antes de la ultima iteracion, de modo que *gasta el presupuesto completo* y usa exactamente las mismas $1{,}2 \times 10^4$ evaluaciones que el resto (evitamos asi cualquier ventaja aparente por terminar antes). NSGA-II es de codificacion real con poblacion 100, cruce SBX y mutacion polinomica; en la CNC optimiza los dos objetivos reales (minimizar F, maximizar la MRR) con la igualdad de R_a como restriccion (dominancia con restricciones de Deb), y en la HEA hace busqueda de factibilidad sobre el simplex; la robustez **no** es un objetivo, se selecciona despues igual que en nuestro metodo. Las metaheuristicas de `pymoo` (GA, DE, PSO con poblacion 100; CMA-ES con reinicios IPOP) usan una terminacion por numero de evaluaciones para igualar exactamente el presupuesto. Todas reciben el mismo sustituto congelado, las mismas restricciones y el mismo operador de reparacion; el criterio de factibilidad (banda de igualdad mas simplex) es identico.

De aqui extraemos conclusiones *honestas*, y ninguna consiste en que un metodo domine a los demas. Primera, la reparacion es el factor decisivo de factibilidad: sin ella la restriccion de simplex de la HEA es inviable por muestreo (0 % de factibilidad, residuo medio 0,99), mientras que con ella se

satisface de forma exacta ($|\sum x - 1| = 0$) en todos los metodos (Tabla 1). El operador de reparacion no es una aportacion de este trabajo: procede de la linea de trabajo companion sobre optimizacion de respuesta (Scala y Lopez, 2026), y aqui lo damos por igual a todas las lineas base para que la comparacion sea limpia. Segunda, la robustez no la optimiza ningun metodo: es una seleccion *posterior* que aplicamos por igual al conjunto factible de cada uno (Seccion 2.4); en esta version NSGA-II ya **no** optimiza la sensibilidad, sino los objetivos reales (minimizar F, maximizar la MRR). La consecuencia honesta es que el punto mas robusto disponible tiende a aparecer en los conjuntos mas amplios: el rechazo, que cubre casi todo el dominio ($\sim 100\,\%$), contiene los puntos mas planos (menor S, 0,055 en CNC), mientras que los optimizadores, que concentran su poblacion –nuestra contraccion (79 %) o NSGA-II sobre el frente F–MRR (45 %)– devuelven conjuntos menores con un mejor S mas alto. Cobertura y robustez del mejor punto van, pues, de la mano; la distincion relevante entre metodos esta en el riesgo de extrapolacion (mas abajo). Tercera, el valor no esta en ganar un eje concreto sino en ofrecer, en una unica pasada sin derivadas, la *variedad completa* de un objetivo fijado, el manejo de *sentidos mixtos* (minimizar F y maximizar la MRR sobre la banda, Seccion 3) y una *seleccion por robustez* que extrae de la variedad un diseno robusto sin una optimizacion aparte; las lineas base, en cambio, resuelven cada una un solo eje (la cobertura, o el objetivo escalar).

Optimizacion de sentido mixto frente a metaheuristicas. La cobertura pura no distingue a un optimizador de un muestreador porque, con un objetivo solo fijado, todas las soluciones factibles son equivalentes. La diferencia aparece al anadir un objetivo secundario. En la tarea de sentido mixto de la CNC (fijar R_a y *minimizar* F) comparamos, con el mismo sustituto exportado y el mismo presupuesto (exactamente $1{,}2 \times 10^4$ evaluaciones para todos), contra el NSGA-II reconvertido (que aqui optimiza F y la MRR, no la robustez) y contra metaheuristicas de `pymoo` (GA, DE, PSO, CMA-ES) con la misma reparacion (Tabla 2). Nuestro metodo alcanza la menor fuerza factible (78,0 N), al nivel de los mejores optimizadores (NSGA-II, DE y PSO, todos 78,0 N) y por delante de GA (87,5 N, +12 %), del muestreo por rechazo (86,6 N, +11 %) y de CMA-ES (114,8 N, +47 %). No afirmamos superarlos: con el mismo presupuesto empatamos con ellos en el objetivo escalar. El valor de nuestro planteamiento no es una fuerza menor, sino que *la misma pasada* que alcanza ese optimo devuelve ademas la variedad completa del objetivo fijado y su ordenacion por robustez, algo que ninguno de ellos produce (cada

Cuadro 2: Tarea de sentido mixto (CNC: fijar R_a, minimizar F). Mejor fuerza factible F (menor es mejor). Misma reparacion y el mismo presupuesto exacto de $1{,}2 \times 10^4$ evaluaciones reales del sustituto para todos los metodos.

Metodo	mejor F [N]
Nuestro (contraccion)	**78.0**
NSGA-II (min F, max MRR)	78.0
DE	78.0
PSO	78.0
Rechazo (muestreo)	86.6
GA	87.5
CMA-ES	114.8

uno devuelve un unico optimo, o a lo sumo un frente, pero no la variedad de la especificacion con su seleccion). En la HEA, con la misma reparacion las cuatro metaheuristicas (GA, DE, PSO y CMA-ES) satisfacen el simplex de forma exacta y alcanzan la banda de dureza; sin reparacion, en cambio, la igualdad de medida nula es inviable por muestreo (Tabla 1). La reparacion es el habilitador, no un detalle.

Riesgo de extrapolacion de la variedad completa. La discusion de la Seccion 2.4 sugiere una pregunta que podemos medir sobre *todas* las soluciones devueltas, no solo sobre el punto seleccionado: ¿que metodo produce una variedad que se apoya menos en el borde del soporte de entrenamiento, donde el sustituto extrapola? Para cada punto factible medimos su margen a las paredes de la caja (centralidad) y su distancia al dato de entrenamiento mas cercano, normalizada por rango (Figura 4). Los dos criterios miden riesgos distintos y no coinciden. Por *cercania al dato*, NSGA-II es el mas proximo (0,11), porque al perseguir los extremos de F y MRR se posa sobre recetas extremas reales; le sigue nuestra variedad (0,15) y, ultimo, el rechazo (0,18–0,19). Por *centralidad*, el orden se invierte: NSGA-II queda pegado a las paredes (99 % de sus puntos con margen $< 0{,}1$, en el borde del soporte, donde el dato es unilateral y la prediccion menos fiable), el rechazo deja un 22–31 % en el borde y nuestra contraccion solo un 6 %. La lectura honesta es que *nuestra variedad es la unica favorable en ambos ejes*: cerca de los datos y en el interior del dominio; cada linea base falla uno (el rechazo se aleja del dato; NSGA-II se apoya en la frontera). En la HEA, donde el simplex hace que todos rocen las paredes, el criterio informativo es la distancia al

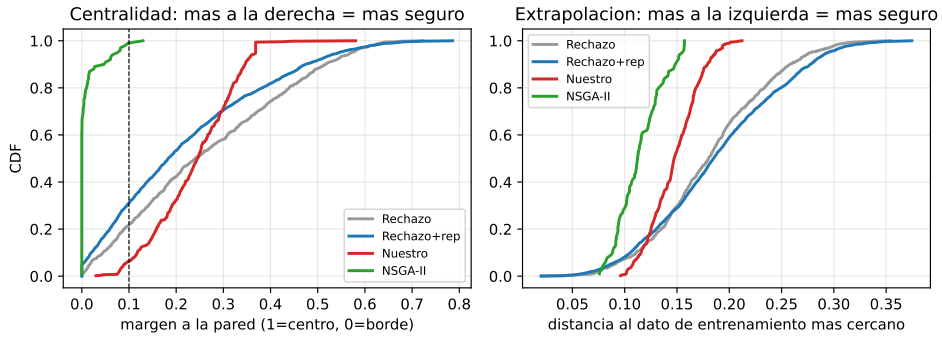


Figura 4: Distribucion (CDF) sobre *toda* la variedad factible de la CNC. Izquierda: centralidad (margen a la pared); mas a la derecha es mas seguro. Derecha: distancia al dato de entrenamiento mas cercano; mas a la izquierda es mas seguro. Nuestra variedad (rojo) es la unica favorable en ambos paneles: interior y cerca de los datos. NSGA-II (verde), que aqui optimiza F y MRR, se posa sobre muestras extremas (cerca del dato) pero en la frontera del dominio; el rechazo (gris/azul) se aleja mas del dato.

dato, y de nuevo la nuestra es la mas cercana (0,16 frente a 0,22 y 0,27). La contrapartida es que la nuestra es una variedad mas pequena (menor cobertura, Tabla 1): compramos seguridad frente a la extrapolacion a cambio de amplitud.

En resumen, el rechazo reparado es una linea base simple y fuerte para cubrir la variedad de un objetivo unico; el NSGA-II reconvertido es un optimizador multiobjetivo legitimo que iguala nuestra fuerza minima (78,0 N) pero concentra sus disenos en la frontera del dominio; y en la optimizacion de sentido mixto nuestro metodo iguala a los mejores optimizadores con el mismo presupuesto y supera al muestreo, a GA y a CMA-ES. El valor del planteamiento como *problema inverso* no reside en ganar un eje aislado, sino en unificar en una sola pasada la recuperacion de la variedad, los sentidos mixtos y la seleccion por robustez sobre modelos sustitutos reparados, con una variedad que ademas es la unica que se mantiene a la vez cerca de los datos y en el interior del dominio (Figura 4), reportando con transparencia donde cada linea base es preferible.

6. Conclusiones

Hemos planteado el diseno inverso como la recuperacion de la variedad factible definida por restricciones de igualdad sobre una red sustituta, con

objetivos de sentido mixto y una seleccion por robustez. En dos casos con datos reales, el metodo recupera variedades ricas de disenos que cumplen la especificacion, con satisfaccion exacta de las restricciones afines (incluido el simplex composicional), y extrae de ellas el diseno mas robusto. La comparacion honesta de la Seccion 5, que dota a las lineas base de la misma reparacion, deja claro que la reparacion es el factor decisivo de factibilidad y que la aportacion propia del metodo son los objetivos de sentido mixto y la seleccion por robustez; para la mera cobertura de un objetivo unico, el rechazo reparado es una linea base simple y competitiva, y un evolutivo multiobjetivo (NSGA-II) con la misma reparacion iguala nuestra fuerza minima. Ningun metodo domina, y ninguno optimiza la robustez (es siempre una seleccion posterior); la particularidad favorable de nuestra variedad es que es la unica que se mantiene a la vez cerca de los datos de entrenamiento y en el interior del dominio, es decir, la mas prudente frente a la extrapolacion del sustituto. El trabajo futuro incluye ampliar el panel de lineas base (metaheuristicas y programacion no lineal con presupuesto compartido, como en la linea companion), la extension a bandas de especificacion y a objetivos de igualdad multiples simultaneos.

Reproducibilidad

El codigo, los modelos sustitutos y los datos que reproducen las figuras y todas las cifras estan disponibles en el repositorio companion (directorio `rerun/`), construido sobre la biblioteca OpenNN. El analisis de extrapolacion se obtiene con `analyze_extrapolation.py` sobre los conjuntos factibles volcados por `baselines`.

Referencias

Scala, S., Lopez, R., 2026. Una jerarquia de reparacion de restricciones para la optimizacion factible por construccion sobre redes neuronales sustitutas. Manuscrito companion (optimizacion de respuesta).

Canal, G., Borille, A. V., 2022. CNC turning roughness, forces and tool wear (AISI 304). Conjunto de datos, Kaggle. DOI 10.34740/kaggle/dsv/3702243.

Wen, C., Zhang, Y., Wang, C., et al., 2019. Machine learning assisted design of high entropy alloys with desired property. Acta Materialia 170, 109–117.