ScienceDirect
www.sciencedirect.com

Revista Iberoamericana de Automatica e Informatica industrial 00 (2026) 1–7

RIAI
www.elsevier.es/RIAI

Problemas inversos con objetivos mixtos y restricciones de igualdad sobre redes neuronales sustitutas

S. Scala[a,*], R. López[a]

[a]*Artelnics, Salamanca, España.*

Resumen

Copyright © 2026 CEA.

El diseño industrial óptimo suele plantearse como la búsqueda de un único punto óptimo sobre un modelo sustituto entrenado con datos. Muchos problemas de ingeniería, sin embargo, no piden un óptimo sino *una especificación*: un valor objetivo que debe alcanzarse exactamente (un acabado, una dureza, una carga). En este trabajo tratamos el diseño inverso como la recuperación del *conjunto factible completo* (la variedad de soluciones) que satisface una especificación impuesta como restricción de igualdad sobre la salida de una red neuronal sustituta. Sobre ese planteamiento construimos un esquema de optimización de respuesta de *sentido mixto*, en el que distintas salidas del mismo problema pueden minimizarse, maximizarse o fijarse simultáneamente, y un criterio de selección que ordena las soluciones de la variedad por su *robustez*, calculada con el Jacobiano analítico de la red, equilibrada con su centralidad en el dominio. El método maneja de forma nativa restricciones de caja, afines (incluido el símplex composicional) y no lineales. Lo validamos en dos casos con datos reales y solo variables numéricas: el torneado CNC de acero inoxidable AISI 304 (fijar la rugosidad y recorrer el compromiso entre fuerza de corte y tasa de arranque de material) y la dureza de aleaciones de alta entropía sobre el símplex de composición (fijar la dureza y recuperar la variedad de aleaciones factibles). En ambos casos se recupera una variedad rica y diversa de diseños que cumplen la especificación, con satisfacción exacta de las restricciones afines, y se selecciona de ella el diseño más robusto. Una comparación honesta, en la que damos la misma reparación a las líneas base, muestra que la reparación es el factor decisivo de factibilidad (sin ella la restricción de símplex es inviable por muestreo) y que la aportación propia del método son los objetivos de sentido mixto y la selección por robustez; con el mismo presupuesto de evaluaciones, nuestro método iguala a los mejores optimizadores de propósito general en el objetivo escalar y además devuelve, en la misma pasada, la variedad completa y su ordenación por robustez. En el caso de dominio de caja, la variedad que recupera es además la que menos extrapola el sustituto: se mantiene más cerca de los datos de entrenamiento que las de las líneas base.

Palabras Clave: diseño inverso, optimización de respuesta, redes neuronales sustitutas, restricciones de igualdad, robustez, objetivos mixtos

1. Introducción

La cadena habitual del diseño industrial guiado por datos entrena un modelo sustituto $f : \mathbb{R}^p \to \mathbb{R}^q$ (a menudo una red neuronal) sobre medidas experimentales o de simulación, y después busca condiciones de operación que optimicen una o varias salidas. En un trabajo companion abordamos esta búsqueda como *optimización de respuesta*, con estrategias sin derivadas que explotan el bajo coste de evaluar la red y proyectan (reparan) las muestras sobre las restricciones antes de evaluarlas, garantizando la factibilidad por construcción (Scala y López, 2026). El operador de reparación de restricciones es maquinaria común de esa línea; en este trabajo lo reutilizamos y no lo reclamamos como aportación.

Aquel planteamiento devuelve un único óptimo factible (o un frente de Pareto). Aquí adoptamos una perspectiva distinta, la del *problema inverso*. Además, una parte importante de los problemas de ingeniería no se formula como "optimizar", sino como "alcanzar una especificación": fabricar una pieza con un acabado superficial dado, una aleación con una dureza dada, un proceso que opere a una carga dada. En estos casos el objetivo natural es una *restricción de igualdad* sobre la salida, $f_k(\mathbf{x}) = c$, y su solución no es un punto sino una *variedad*: el conjunto de todas las recetas que cumplen la especificación. Recuperar esa variedad, en lugar de un solo representante, tiene valor práctico directo: permite elegir después, entre todas las soluciones

*Autor en correspondencia.

Correos electrónicos: COMPLETAR@artelnics.com (S. Scala), COMPLETAR@artelnics.com (R. López)

equivalentes en la especificación, la que mejor satisface criterios secundarios (coste, productividad) o la más robusta frente a errores de fabricación.

Este artículo desarrolla esa idea con tres contribuciones. Primera, planteamos el diseño inverso como la recuperación de la variedad factible definida por una o varias restricciones de igualdad sobre la red sustituta (Sección 2). Segunda, generalizamos la formulación a *objetivos de sentido mixto*, en los que sobre un mismo problema conviven salidas a minimizar, a maximizar y a fijar. Tercera, introducimos un criterio de selección que ordena las soluciones de la variedad por robustez, medida con el Jacobiano analítico de la red y ponderada por el dominio, y la equilibra con la centralidad del punto en la caja de diseño. Al tratarse de una recuperación de conjunto y no de una relajación, la especificación puede exigirse además de forma *exacta*, sin tolerancia elegida por el usuario, algo que el muestreo por rechazo no alcanza. El método se valida en dos casos con datos reales y variables numéricas (Secciones 3 y 4).

2. Optimización de respuesta de sentido mixto

2.1. Planteamiento

Sea $f : \mathcal{X} \subseteq \mathbb{R}^p \to \mathbb{R}^q$ una red neuronal entrenada, con entradas $\mathbf{x}$ acotadas a una caja $\mathcal{X} = \prod_i [l_i, u_i]$. A cada salida j se le asigna un *sentido* $s_j \in \{\min, \max, \text{fijo}\}$. Las salidas "fijo" llevan un valor objetivo c_j; las salidas "min"/"max" definen los objetivos de optimización. Además se admiten restricciones sobre entradas y salidas: de caja, afines $\mathbf{a}^\top \mathbf{x} \bowtie \beta$ (incluido el símplex $\sum_i x_i = 1$) y no lineales $g(\mathbf{x}) \bowtie \beta$.

2.2. Objetivo fijo y variedad factible

Un objetivo de igualdad $f_k(\mathbf{x}) = c_k$ se impone como una banda estrecha $|f_k(\mathbf{x}) - c_k| \le \varepsilon$ alrededor del valor objetivo. El optimizador muestrea el dominio, repara las muestras sobre las restricciones afines, evalúa la red y retiene las que caen en la banda, contrayendo iterativamente el dominio alrededor de la región factible. El resultado no es un punto sino un conjunto de soluciones $\{\mathbf{x}^{(r)}\}$ que aproxima la variedad $\mathcal{M}_c = \{\mathbf{x} \in \mathcal{X} : f_k(\mathbf{x}) = c_k\}$.

La banda ε es solo un *mecanismo de recolección*: sirve para retener muchos puntos de la variedad, no para relajar la especificación. Como la contracción del dominio concentra el muestreo alrededor del valor objetivo, el método no necesita que el usuario fije una tolerancia; puede pedirse el valor *exacto* ($\varepsilon \to 0$) y la contracción sigue devolviendo un conjunto poblado de soluciones cuyo residuo $|f_k(\mathbf{x}) - c_k|$ tiende a cero. Esto distingue el planteamiento del muestreo por rechazo, que no puede acertar un objetivo de medida nula: su conjunto factible se vacía al estrechar la banda (Sección 5).

2.3. Sentidos mixtos

Cuando junto a una salida fija coexisten salidas a minimizar o maximizar, la igualdad se mantiene como banda y los sentidos min/max se optimizan sobre ella, devolviendo el frente de compromiso restringido a la variedad. Así, un mismo problema puede, por ejemplo, *fijar* una salida y *minimizar* otra, como en el Caso A (Sección 3: fijar R_a, minimizar F), donde además la tasa de arranque de material (MRR) –función analítica de las entradas– se recorre como compromiso a lo largo de la variedad. Fijar simultáneamente dos salidas ($f_{k_1} = c_1$ y $f_{k_2} = c_2$) recupera la intersección de dos variedades.

2.4. Robustez y selección

Todas las soluciones de $\mathcal{M}_c$ cumplen la especificación por igual; se distinguen por su sensibilidad a errores en las entradas. Definimos la robustez de una solución mediante el Jacobiano analítico de la red, ponderado por el tamaño del dominio de cada entrada,

$$S(\mathbf{x}) \;=\; \sqrt{\sum_{i=1}^{p} \Big(\frac{\partial f_k}{\partial x_i}(\mathbf{x})\,(u_i - l_i) \Big)^2}, \tag{1}$$

de modo que S estima la deriva de la salida si cada entrada se desviara en una fracción de su rango. Un valor menor indica un diseño más manufacturable. El Jacobiano se obtiene con el mismo motor de diferenciación que emplea el optimizador (validado frente a diferencias finitas). Para combinarla con la centralidad, normalizamos S al intervalo $[0, 1]$ sobre el conjunto devuelto y la invertimos, $R(\mathbf{x}) = 1 - \hat{S}(\mathbf{x})$ (mayor R, más robusto). La selección final combina esa robustez R y la *centralidad* $C(\mathbf{x})$, definida como el menor margen normalizado de la solución a las paredes de la caja de diseño (1 en el centro, 0 sobre una pared), con un único parámetro $\alpha \in [0, 1]$ mediante la media geométrica $C^{1-\alpha} R^{\alpha}$, de forma que $\alpha = 0$ elige el diseño más central y $\alpha = 1$ el más robusto.

La centralidad no es un mero desempate: es una salvaguarda frente al propio modelo. La robustez S se estima con el Jacobiano del *sustituto*, y ese sustituto solo es fiable dentro del soporte de los datos de entrenamiento. Una solución con margen pequeño se sitúa en el borde de la caja, justo donde la red extrapola y sus unidades se saturan; allí su Jacobiano, y por tanto la robustez que le atribuimos, es menos digno de confianza. Por eso, ante el riesgo de extrapolación, conviene preferir un punto más central (un α moderado, en torno a 0,5) que sacrifica algo de robustez nominal a cambio de una predicción en la que podemos confiar. La selección se resuelve sobre cada variedad por separado, de modo que el punto equilibrado depende de la geometría concreta de $\mathcal{M}_c$.

3. Caso A: torneado CNC de AISI 304

Datos y sustituto. Partimos de una campaña factorial replicada de torneado de acero inoxidable austenítico AISI 304 (Canal y Borille, 2022). Las variables de decisión (numéricas) son la velocidad de corte v_c, el avance f y la profundidad de pasada a_p, junto con el estado de desgaste de la herramienta VB tratado como variable numérica. Las respuestas son la rugosidad media R_a y la fuerza de corte resultante F; la tasa de arranque de material MRR $= v_c\, f\, a_p$ es analítica. Entrenamos una red sustituta multisalida $(v_c, f, a_p, VB) \to (R_a, F)$ con selección de arquitectura de neuronas. La fuerza se predice con precisión ($R^2 \approx 0{,}99$); la rugosidad, dominada por el avance pero con dispersión de réplicas, alcanza $R^2 \approx 0{,}7$ y su dispersión define la tolerancia natural de la banda de igualdad.



Figura 1: Caso A. Compromiso de sentido mixto sobre la variedad de R_a fijo: cada punto es una receta con la rugosidad en la especificación; el eje horizontal es la fuerza a minimizar y el vertical la MRR a maximizar, coloreados por la robustez S de la ecuación (1).

Diseño de sentido mixto. Planteamos el problema mixto: *fijar* R_a en una especificación de acabado y recuperar la variedad de recetas que la cumplen, sobre la cual la fuerza F (a minimizar) y la productividad MRR (a maximizar) se contraponen. Fijado el objetivo de rugosidad en un valor alcanzable del rango del sustituto (aquí $R_a \approx 0{,}62$ μm), el optimizador recupera una variedad de **3400 recetas** que mantienen R_a dentro de la banda $[0{,}605, 0{,}638]$ μm. Sobre esa variedad, la fuerza recorre $[95, 402]$ N y la MRR $[8{,}0, 27{,}5]$, de modo que ambos criterios compiten a lo largo del conjunto factible y uno elige la receta según su prioridad (Figura 1). Como el problema solo tiene tres palancas continuas, la variedad de R_a constante es una superficie bidimensional directamente visualizable en el espacio de decisión (Figura 2).

Selección y multiobjetivo de igualdad. El criterio de la Sección 2.4 devuelve recetas distintas según α (más central frente a más robusta), que difieren claramente en fuerza y productividad sobre la misma especificación de rugosidad. La diferencia no es solo de valor: sobre esta variedad de 3400 recetas, la receta de robustez pura ($\alpha = 1$) tiene un margen a las paredes de apenas 0,04, es decir, se apoya casi sobre el borde de la caja de entrenamiento, donde el sustituto extrapola; al bajar a $\alpha = 0{,}5$ y $\alpha = 0$ el margen sube a 0,51 y 0,58, devolviendo recetas en el interior bien muestreado del dominio. En la práctica preferimos ese punto más central como cobertura frente al riesgo de extrapolación del modelo (Sección 2.4). Al añadir la minimización explícita de F bajo la rugosidad fija, el solver alcanza una receta de fuerza mínima ($F \approx 78$ N). Finalmente, fijando simultáneamente R_a y F se recupera la intersección de ambas variedades (5100 soluciones), que ilustra la capacidad multiobjetivo de igualdad.

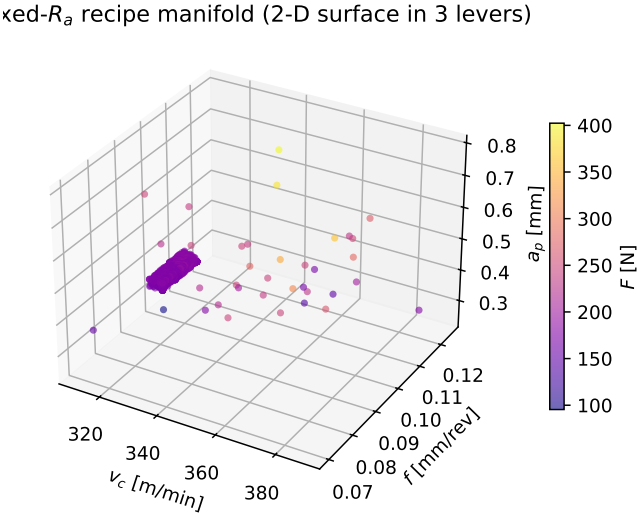


Figura 2: Caso A. La variedad de recetas con R_a fijo es una superficie bidimensional en las tres palancas continuas (v_c, f, a_p), coloreada por la fuerza de corte F.

4. Caso B: dureza de aleaciones de alta entropía sobre el símplex

Datos y sustituto. El segundo caso usa una tabla pública de dureza Vickers de aleaciones de alta entropía (Wen et al., 2019). Las entradas son las diez fracciones atómicas (Al, Co, Cr, Cu, Fe, Mn, Mo, Ni, Ti, V), que suman uno, y la salida es la dureza HV. El sustituto alcanza $R^2 \approx 0{,}87$ sobre 370 aleaciones. La composición impone la restricción afín de *símplex* $\sum_i x_i = 1$, la prueba canónica del operador de reparación afín.

Recuperación de la variedad de aleaciones. Fijamos la dureza en un valor alcanzable ($HV \approx 538$) y recuperamos la variedad de composiciones que la producen. El optimizador devuelve **183 aleaciones** distintas, todas sobre el símplex con error máximo $|\sum_i x_i - 1| = 0$ (satisfacción exacta de la restricción afín). La variedad es diversa: cada fracción recorre entre el 39 % y el 99 % de su rango admisible (Figura 3), lo que muestra que existen familias de aleaciones muy distintas con la misma dureza. Sobre ese conjunto, la robustez de la ecuación (1) separa las composiciones poco sensibles a la variación de composición de las muy sensibles, y la selección centralidad–robustez recomienda la aleación más manufacturable.

5. Comparación honesta con líneas base

Para separar la aportación real del método de la de la reparación, damos a las líneas base *el mismo operador de reparación* que usa nuestro método. Sobre un presupuesto comparable de evaluaciones y con un criterio de factibilidad idéntico (banda de igualdad en la salida más la restricción de símplex en las entradas), comparamos: muestreo por rechazo *sin* reparación; muestreo por rechazo *con* reparación (una ronda de muestreo, reparación afín de entradas, reparación de la salida y filtrado, exactamente los mismos operadores); nuestro método iterativo con contracción del dominio; y, para el objetivo escalar, las

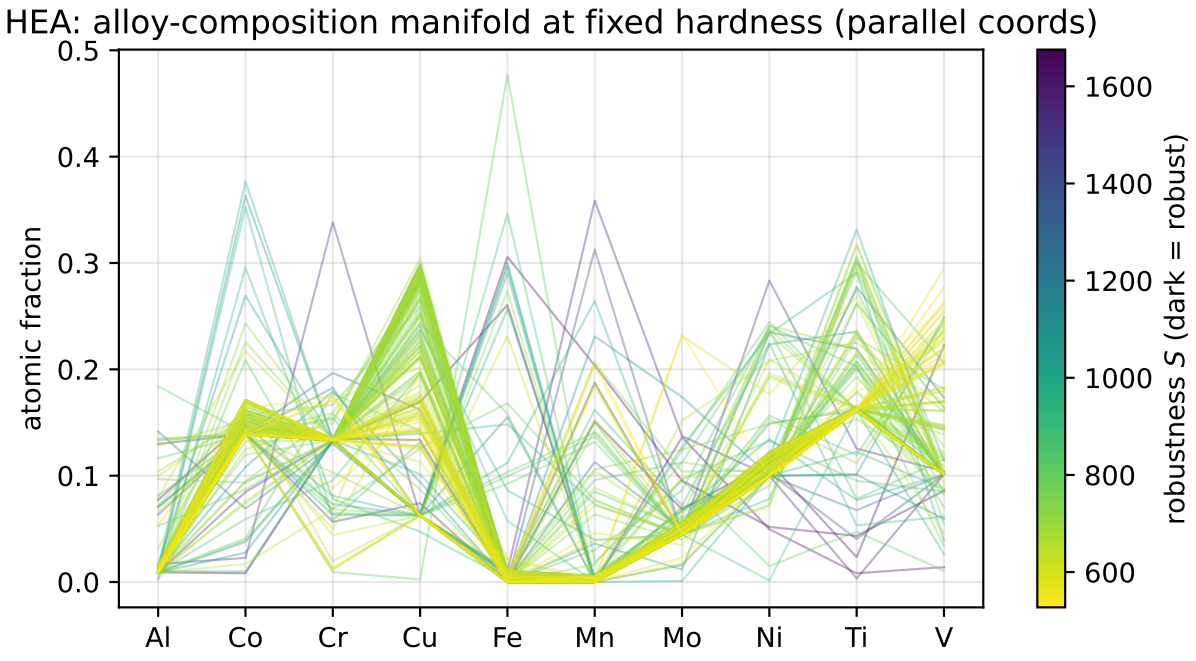


Figura 3: Caso B. Variedad de composiciones con dureza fija, en coordenadas paralelas sobre las diez fracciones atómicas (suma uno). El color codifica la robustez S; las trayectorias oscuras son las aleaciones más robustas.

metaheurísticas de propósito general de `pymoo` (Blank y Deb, 2020). Todas las líneas base reciben el mismo sustituto congelado, las mismas restricciones y el mismo presupuesto de evaluaciones. La Tabla 1 resume los resultados y la Figura 4 ilustra el análisis de extrapolación que los distingue.

Protocolo. El presupuesto es de $1{,}2\times10^4$ evaluaciones del sustituto para todos los métodos, contado con el número real de propagaciones directas (incluidas las de la reparación). Para que la comparación sea estrictamente equitativa, ajustamos nuestro método a 6 iteraciones de 2×10^3 muestras: con esta configuración la contracción no puede detenerse antes de la última iteración, de modo que *gasta el presupuesto completo* y usa exactamente las mismas $1{,}2\times10^4$ evaluaciones que el resto (evitamos así cualquier ventaja aparente por terminar antes). Las metaheurísticas de `pymoo` (GA, DE, PSO con población 100; CMA-ES con reinicios IPOP) usan una terminación por número de evaluaciones para igualar exactamente el presupuesto. Todas reciben el mismo sustituto congelado, las mismas restricciones y el mismo operador de reparación; el criterio de factibilidad (banda de igualdad más símplex) es idéntico.

De aquí extraemos conclusiones *honestas*, y ninguna consiste en que un método domine a los demás. Primera, la reparación es el factor decisivo de factibilidad: sin ella la restricción de símplex de la HEA es inviable por muestreo (0 % de factibilidad, residuo medio 0,98), mientras que con ella se satisface de forma exacta ($|\sum x - 1| = 0$) en todos los métodos (Tabla 1). El operador de reparación no es una aportación de este trabajo: procede de la línea de trabajo companion sobre optimización de respuesta (Scala y López, 2026), y aquí lo damos por igual a todas las líneas base para que la comparación sea limpia. Conviene precisar, sobre la exactitud en el símplex: la restricción afín se cumple a *precisión de máquina* en todo método que aplique la reparación –nuestro $|\sum x - 1| \approx 8\times10^{-8}$ es el suelo de la precisión simple (float32) con que opera la red, y las metaheurísticas reparadas, que operan en doble precisión, alcanzan $\sim 10^{-17}$–. Es decir, la exactitud sobre el símplex proviene de la reparación afín compartida, no es una particularidad de nuestro método; la exactitud propia de nuestro planteamiento es la del *objetivo de igualdad en la salida*, que recupera la variedad en el valor exacto sin tolerancia (Tabla 3), y se observa en el dominio de caja de la CNC. Segunda, la robustez no la optimiza ningún método: es una selección *posterior* que aplicamos por igual al conjunto factible de cada uno (Sección 2.4). La consecuencia honesta es que el punto más robusto disponible tiende a aparecer en los conjuntos más amplios: el rechazo reparado, que cubre casi todo el dominio ($\sim$ 100 %), contiene los puntos más planos (menor S, 0,067 en la CNC), mientras que nuestra contracción, que concentra su población sobre la región factible

Tabla 1: Comparación con la misma reparación, mismo presupuesto de evaluaciones ($1{,}2\times10^4$ para todos los métodos) y criterio de factibilidad idéntico (banda de igualdad y símplex). Cobertura = relleno medio del dominio por las soluciones factibles; robustez = menor S disponible en el conjunto devuelto (selección posterior, menor es mejor; ningún método optimiza S). Caso CNC; la HEA se comenta en el texto.

Método	Reparación	Factib.	Cobertura	Robustez m
Rechazo	no	7.5 %	99.6 %	0.092
Rechazo	sí	**21.5 %**	**99.9 %**	**0.067**
Nuestro (iterativo)	sí	3.1 %	72.3 %	0.108

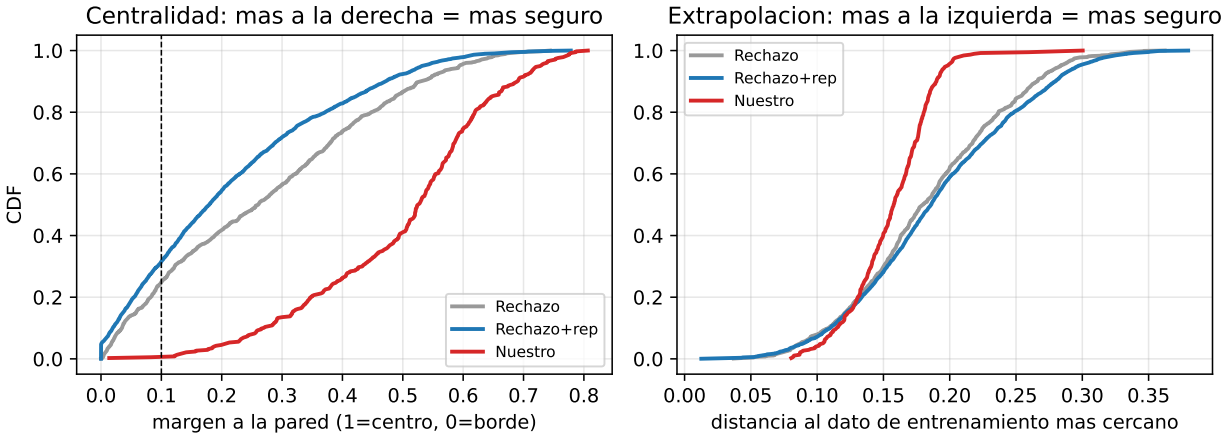


Figura 4: Distribución (CDF) sobre *toda* la variedad factible de la CNC. Izquierda: centralidad (margen a la pared); más a la derecha es más seguro. Derecha: distancia al dato de entrenamiento más cercano; más a la izquierda es más seguro. Nuestra variedad (rojo) es favorable en ambos paneles: se mantiene en el interior del dominio y cerca de los datos; el rechazo (gris/azul) se dispersa hacia el borde y se aleja más del dato.

(72 % de cobertura), devuelve un conjunto menor cuyo mejor S es algo más alto (0,108). Cobertura y robustez del mejor punto van, pues, de la mano; la distinción relevante entre métodos está en el riesgo de extrapolación (más abajo). Tercera, el valor no está en ganar un eje concreto sino en ofrecer, en una única pasada sin derivadas, la *variedad completa* de un objetivo fijado, el manejo de *sentidos mixtos* (minimizar F sobre la banda y navegar el compromiso con la MRR, Sección 3) y una *selección por robustez* que extrae de la variedad un diseño robusto sin una optimización aparte; las líneas base, en cambio, resuelven cada una un solo eje (la cobertura, o el objetivo escalar).

Optimización de sentido mixto frente a metaheurísticas. La cobertura pura no distingue a un optimizador de un muestreador porque, con un objetivo solo fijado, todas las soluciones factibles son equivalentes. La diferencia aparece al añadir un objetivo secundario. En la tarea de sentido mixto de la CNC (fijar R_a y *minimizar* F) comparamos, con el mismo sustituto exportado y el mismo presupuesto (exactamente $1{,}2{\times}10^4$ evaluaciones para todos), contra metaheurísticas de propósito general de `pymoo` (Blank y Deb, 2020): GA (Goldberg, 1989), DE (Storn y Price, 1997), PSO (Kennedy y Eberhart, 1995) y CMA-ES (Hansen y Ostermeier, 2001), con la misma reparación (Tabla 2). Nuestro método alcanza una fuerza factible de 78,1 N, prácticamente al nivel de los mejores optimizadores (DE y PSO, 78,0 N) y por delante de GA (87,5 N, +12 %), del muestreo por rechazo (93,5 N, +20 %) y de CMA-ES (114,8 N, +47 %). No afirmamos superar a DE ni a PSO: con el mismo presupuesto empatamos con ellos en el objetivo escalar. El valor de nuestro planteamiento no es una fuerza menor, sino que *la misma pasada* que alcanza ese óptimo devuelve además la variedad completa del objetivo fijado y su ordenación por robustez, algo que ninguna metaheurística produce (cada una devuelve un único óptimo escalar). En la HEA, con la misma reparación las cuatro metaheurísticas (GA, DE, PSO y CMA-ES) satisfacen el símplex de forma exacta y alcanzan la banda de dureza; sin reparación, en cambio, la igualdad de medida nula es inviable por muestreo

Tabla 2: Tarea de sentido mixto (CNC: fijar R_a, minimizar F). Mejor fuerza factible F (menor es mejor). Misma reparación y el mismo presupuesto exacto de $1{,}2 \times 10^4$ evaluaciones reales del sustituto para todos los métodos.

Método	mejor F [N]
Nuestro (contracción)	**78.1**
DE	78.0
PSO	78.0
GA	87.5
Rechazo (muestreo)	93.5
CMA-ES	114.8

(Tabla 1). La reparación es el habilitador, no un detalle.

Especificación exacta sin tolerancia. Un rasgo del planteamiento es que la especificación de igualdad puede exigirse de forma *exacta*, sin que el usuario elija una tolerancia. Para medirlo estrechamos la banda $\varepsilon = \delta\,(o_{\text{máx}} - o_{\text{mín}})$ hacia cero y observamos, con el mismo presupuesto de $1{,}2 \times 10^4$ evaluaciones, cuántas soluciones *distintas* devuelve cada método *en* el valor objetivo y con qué diversidad (caso CNC, Tabla 3). Aquí comparamos con *todas* las líneas base, incluidas las metaheurísticas escalares que minimizan $|R_a - c|$. El resultado separa tres comportamientos. El muestreo por rechazo no puede acertar un objetivo de medida nula: su conjunto se vacía al estrechar la banda ($941 \to 100 \to 8 \to 2 \to 0$ soluciones al pasar de $\delta = 10^{-2}$ a 10^{-6}), pues acertar de casualidad es cada vez menos probable. Las metaheurísticas escalares devuelven solo su población (≤ 100 individuos) y, al ser optimizadores de un punto, tienden a *colapsar* sobre una sola receta: GA y CMA-ES convergen a un único diseño (diversidad ≈ 0, cientos de copias del mismo punto), mientras que DE y PSO conservan algo de dispersión pero con pocos supervivientes al estrechar la banda. Nuestra contracción, en cambio, no necesita tolerancia: concentra el presupuesto sobre el objetivo y devuelve un conjunto *poblado y diverso* –1700 recetas con banda 10^{-4}, to-

Tabla 3: Especificación exacta (CNC: fijar R_a) con banda casi nula $\delta = 10^{-4}$, sin tolerancia elegida por el usuario, al mismo presupuesto de $1{,}2 \times 10^4$ evaluaciones. Soluciones *distintas* devueltas *en* el objetivo, su diversidad (relleno medio del dominio) y el mejor residuo $|R_a - c|$. Solo la contracción devuelve un conjunto amplio y diverso (la variedad); las metaheurísticas colapsan sobre uno o pocos puntos y el rechazo se agota. Una ejecución representativa (el muestreo es estocástico).

Método	soluc.	diversidad	mejor residuo
Nuestro (contracción)	**1700**	18 %	2×10^{-7}
Rechazo (muestreo)	8	75 %	6×10^{-6}
DE	28	90 %	4×10^{-8}
PSO	83	34 %	2×10^{-8}
GA	100*	0 %	$\mathbf{2 \times 10^{-13}}$
CMA-ES	63	3 %	1×10^{-6}

*100 copias de un único punto (diversidad nula).

davía 1308 con banda $\sim 10^{-6}$, donde el rechazo ya no devuelve ninguna–. Es decir, recupera la *variedad* en el valor exacto, no un punto. Una salvedad honesta: para un *único* punto exacto un buscador de raíces en doble precisión como GA lo clava más fino ($|R_a - c| \sim 10^{-13}$) que nuestra contracción, cuyo residuo queda en el suelo de la precisión simple de la red ($\sim 2 \times 10^{-7}$); nuestra aportación no es el punto más preciso, sino el *conjunto* de valor exacto que ningún otro método entrega. En la HEA no reproducimos esta prueba: sobre el símplex la variedad de valor exacto, con este presupuesto, ni siquiera nuestra contracción la puebla con banda evanescente (recupera pocas aleaciones), y afirmar una ventaja allí sería deshonesto.

Riesgo de extrapolación de la variedad completa. La discusión de la Sección 2.4 sugiere una pregunta que podemos medir sobre *todas* las soluciones devueltas, no solo sobre el punto seleccionado: ¿qué método produce una variedad que se apoya menos en el borde del soporte de entrenamiento, donde el sustituto extrapola? Para cada punto factible medimos su margen a las paredes de la caja (centralidad) y su distancia al dato de entrenamiento más cercano, normalizada por rango (Figura 4). En la CNC nuestra variedad es la más prudente en *ambos* criterios: por centralidad, solo un 0,5 % de sus puntos quedan en el borde ($< 0{,}1$ de margen), frente al 25–31 % del rechazo; y por cercanía al dato, es la más próxima (0,16 de distancia media, frente a 0,18–0,19 del rechazo). Es decir, la variedad que recuperamos se mantiene a la vez cerca de los datos y en el interior del dominio, donde la predicción del sustituto es más fiable, mientras que el muestreo por rechazo se dispersa hacia el borde y se aleja de los datos. En la HEA no extraemos esta conclusión: con este presupuesto nuestra contracción recupera muy pocas aleaciones factibles (del orden de unidades), demasiado pocas para caracterizar la distribución de la variedad, de modo que las líneas base reparadas la cubren mejor. La contrapartida honesta en la CNC es que la nuestra es una variedad más pequeña (menor cobertura, Tabla 1): compramos seguridad frente a la extrapolación a cambio de amplitud.

En resumen, el rechazo reparado es una línea base simple y fuerte para cubrir la variedad de un objetivo único; en la optimización de sentido mixto nuestro método iguala a los mejores optimizadores de propósito general (DE, PSO) con el mismo presupuesto y supera al muestreo, a GA y a CMA-ES; y cuando la especificación se exige de forma *exacta*, solo la contracción sigue devolviendo la variedad al estrechar la banda hacia cero, mientras el muestreo se queda sin soluciones (Tabla 3). El valor del planteamiento como *problema inverso* no reside en ganar un eje aislado, sino en unificar en una sola pasada la recuperación de la variedad, los sentidos mixtos y la selección por robustez sobre modelos sustitutos reparados, con una variedad que además, en el dominio de caja, se mantiene a la vez cerca de los datos y en el interior del dominio (Figura 4), reportando con transparencia dónde cada línea base es preferible.

6. Conclusiones

Hemos planteado el diseño inverso como la recuperación de la variedad factible definida por restricciones de igualdad sobre una red sustituta, con objetivos de sentido mixto y una selección por robustez. En dos casos con datos reales, el método recupera variedades ricas de diseños que cumplen la especificación, con satisfacción exacta de las restricciones afines (incluido el símplex composicional), y extrae de ellas el diseño más robusto. La comparación honesta de la Sección 5, que dota a las líneas base de la misma reparación, deja claro que la reparación es el factor decisivo de factibilidad y que la aportación propia del método son los objetivos de sentido mixto y la selección por robustez; para la mera cobertura de un objetivo único, el rechazo reparado es una línea base simple y competitiva, y en el objetivo escalar las mejores metaheurísticas de propósito general (DE, PSO) igualan nuestra fuerza mínima. Ningún método domina, y ninguno optimiza la robustez (es siempre una selección posterior); en el caso de dominio de caja, la particularidad favorable de nuestra variedad es que se mantiene a la vez cerca de los datos de entrenamiento y en el interior del dominio, es decir, la más prudente frente a la extrapolación del sustituto. El trabajo futuro incluye ampliar el panel de líneas base (un evolutivo multiobjetivo dedicado y programación no lineal con presupuesto compartido, como en la línea companion), la extensión a bandas de especificación y a objetivos de igualdad múltiples simultáneos.

Reproducibilidad

El código, los modelos sustitutos y los datos que reproducen las figuras y todas las cifras están disponibles en el repositorio companion (directorio `rerun/`), construido sobre la biblioteca OpenNN (Artelnics, 2026). Los experimentos usan una semilla fija (`set_seed(1)`), de modo que las cifras son reproducibles bit a bit; el análisis de extrapolación se obtiene con `analyze_extrapolation.py` sobre los conjuntos factibles volcados por `baselines`. Los estudios de caso (Secciones 3 y 4) recuperan la variedad con un presupuesto de muestreo mayor que el de la comparación controlada de la Sección 5 (fijada en $1{,}2 \times 10^4$ evaluaciones para todos los métodos); los presupuestos exactos figuran en el repositorio.

Referencias

Artelnics, 2026. OpenNN: Open Neural Networks Library. Software, https://www.opennn.net.

Blank, J., Deb, K., 2020. pymoo: Multi-objective optimization in Python. IEEE Access 8, 89497–89509. DOI 10.1109/ACCESS.2020.2990567.

Canal, G., Borille, A. V., 2022. CNC turning roughness, forces and tool wear (AISI 304). Conjunto de datos, Kaggle. DOI 10.34740/kaggle/dsv/3702243.

Goldberg, D. E., 1989. Genetic Algorithms in Search, Optimization, and Machine Learning. Addison-Wesley, Reading, MA.

Hansen, N., Ostermeier, A., 2001. Completely derandomized self-adaptation in evolution strategies. Evolutionary Computation 9 (2), 159–195. DOI 10.1162/106365601750190398.

Kennedy, J., Eberhart, R., 1995. Particle swarm optimization. En: Proceedings of ICNN'95 – International Conference on Neural Networks. Vol. 4. IEEE, pp. 1942–1948. DOI 10.1109/ICNN.1995.488968.

Scala, S., López, R., 2026. Una jerarquía de reparación de restricciones para la optimización factible por construcción sobre redes neuronales sustitutas. Manuscrito companion (optimización de respuesta).

Storn, R., Price, K., 1997. Differential evolution – a simple and efficient heuristic for global optimization over continuous spaces. Journal of Global Optimization 11 (4), 341–359. DOI 10.1023/A:1008202821328.

Wen, C., Zhang, Y., Wang, C., et al., 2019. Machine learning assisted design of high entropy alloys with desired property. Acta Materialia 170, 109–117. DOI 10.1016/j.actamat.2019.03.010.